Теория вероятностей

Математическая статистика

Владимир Анатольевич Судаков

Вероятность против статистики

- Вероятность занимается прогнозированием вероятности будущих событий, а статистика анализирует частоту прошлых событий.
- Вероятность — это теоретическая часть математики, посвященная следствиям определений, а статистика — это прикладная математика, пытающаяся осмыслить наблюдения из реального мира.

Литература

- Вентцель Е.С. Теория вероятностей
- Пугачев В.С. Теория вероятностей и математическая статистика
- Triola, Mario F. Elementary statistics

Математическая статистика

- Разработка методов регистрации, описания и анализа статистических экспериментальных данных, получаемых в результате наблюдения массовых случайных явлений, составляет предмет специальной науки — математической статистики.

- Задачи математической статистики касаются вопросов обработки наблюдений над массовыми случайными явлениями, но в зависимости от характера решаемого практического вопроса и от объема имеющегося экспериментального материала эти задачи могут принимать ту или иную форму.

Типичные задачи статистики

- Определить закон распределения случайной величины (системы случайных величин)
- Проверить правдоподобие гипотез
- Найти неизвестные параметры распределения

Простая статистическая совокупность

- Дана случайная величина X
- Совокупность наблюдаемых значений X - простой статистический ряд (простая статистическая совокупность)
- Статистическая функция распределения X:

$$F^*(x) = P^*(X < x)$$

Визуализация распределений

Продажи Apple iPhone стремительно растут, не так ли?

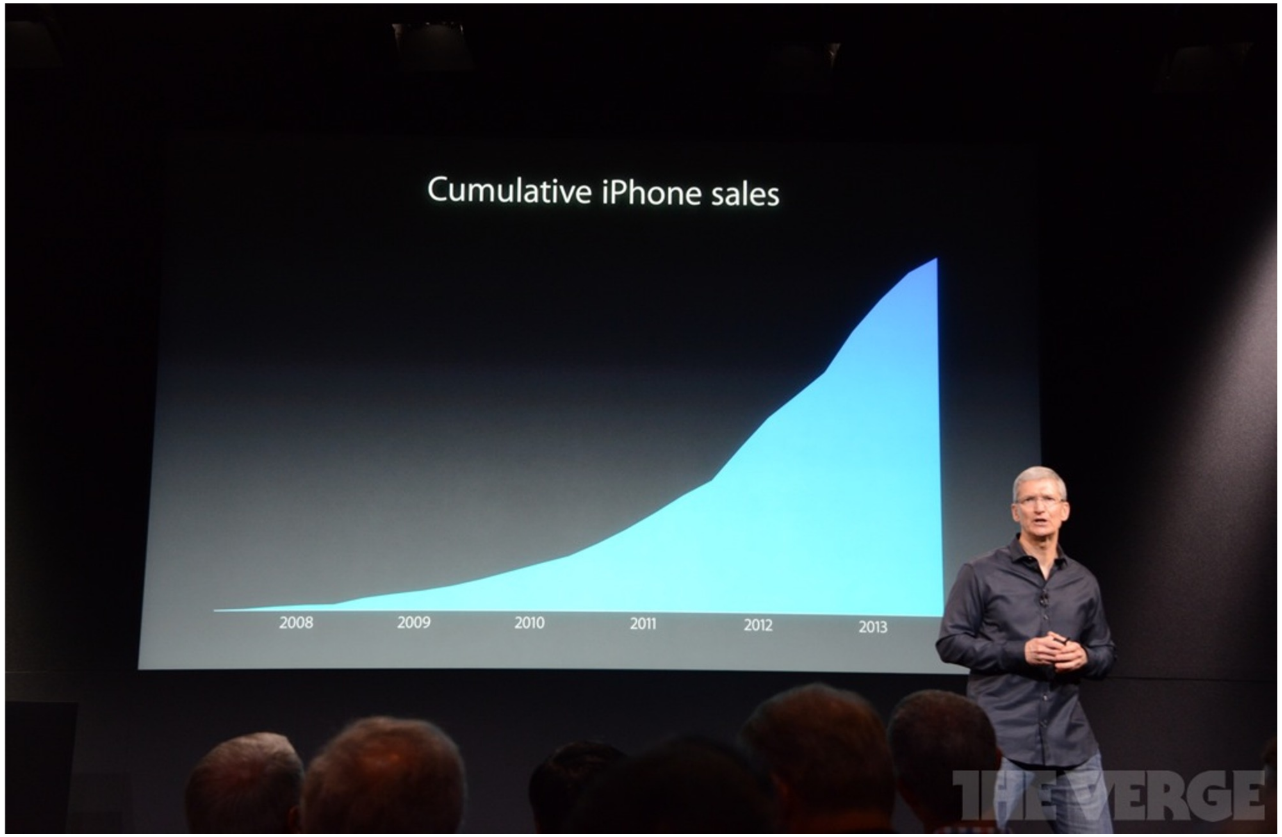

Насколько взрывным является этот рост на самом деле?

Кумулятивные распределения дают ошибочное представление о темпах роста.

Постепенное изменение является производной этой функции, которую трудно визуализировать.

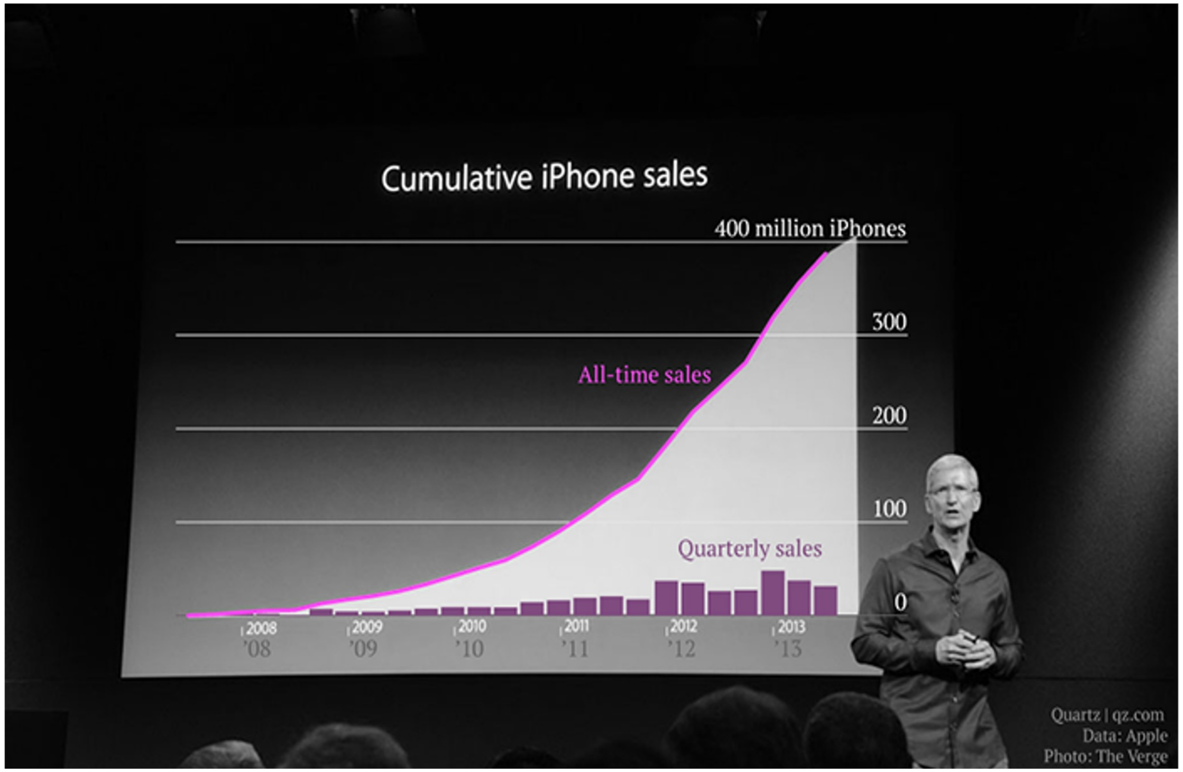

Тренировка

- Дан ряд углов скольжения самолета в момент сбрасывания бомбы

-20,-60,-10, 30, 60, 70, -10,

-30,-120, -100, -80, 20, 40, -60,

-10, 20, 30, -80, 60, 70

- Построить статистическую функцию распределения
- У кого хорошее решение? Какие ошибки типичны на графике

Гистограмма

- Если данных много, то простой статистический ряд не удобен
- Разделим наблюдения на разряды и посчитаем частоты попадания:

$$p_i^* = \frac{m_i}{n}$$

- Таблица с интервалами разрядов и p_i^* называется статистическим рядом

I_i	$x_1;\ x_2$	$x_2;\ x_3$	$\dots$	$x_i;\ x_{i+1}$	$\dots$	$x_k;\ x_{k+1}$
p_i^*	p_1^*	p_2^*	$\dots$	p_i^*	$\dots$	p_k^*

- Что делать если значение попало на границу интервалов?

Давайте посмотрим решение

https://colab.research.google.com/drive/1PnR5vCcxVSRN-VdLX86fgH0fYx-LwMJL

Построение статистической функции распределения

$$F^*(x_1) = 0$$
$$F^*(x_2) = p_1^*$$
$$F^*(x_3) = p_1^* + p_2^*$$
$$\dots$$
$$F^*(x_k) = \sum_{i=1}^{k-1} p_i^*$$
$$F^*(x_{k+1}) = \sum_{i=1}^{k} p_i^* = 1$$

Описательная статистика

Описательная статистика предоставляет способы фиксации свойств данного набора данных/выборки.

- Меры центральной тенденции описывают центр распределения данных.
- Меры вариации или изменчивости описывают разброс данных, т.е. насколько далеко измерения лежат от центра.

Мера центральности: среднее значение

Чтобы вычислить среднее значение, просуммируйте значения и разделите их на количество наблюдений:

$$\mu_X = \frac{1}{n} \sum_{i=1}^{n} x_i$$

Среднее значение имеет смысл для симметричных распределений без выбросов.

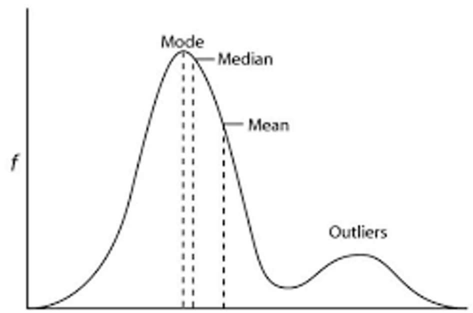

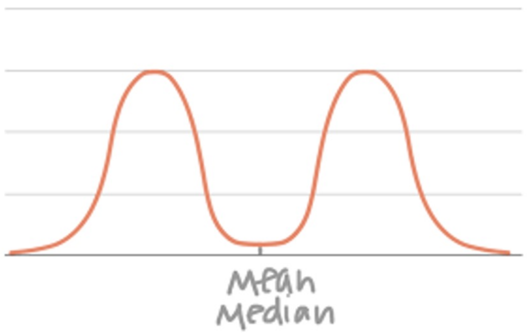

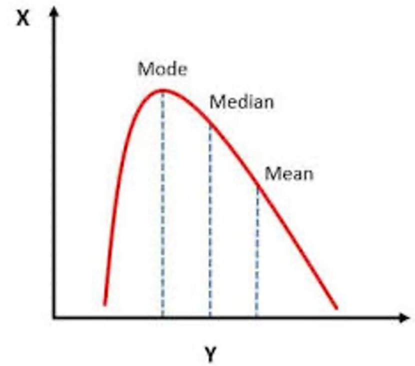

Другие меры центральности

Медиана представляет собой «серединное» значение.

Среднее геометрическое — это корень n-й степени из произведения n значений:

$$\left(\prod_{i=1}^{n} a_i\right)^{1/n} = \sqrt[n]{a_1 a_2 \cdots a_n}.$$

Среднее геометрическое всегда <= среднее арифметическое и более чувствительно к значениям, близким к нулю.

Геометрические средние имеют смысл с соотношениями:

1/2 и 2/1 должны в среднем давать 1.

Какая мера лучше всего?

Среднее значение имеет смысл для симметричных распределений без выбросов: например. рост и вес.

Медиана лучше подходит для асимметричных распределений или данных с выбросами: например, богатство и доход.

Билл Гейтс добавляет 250 долларов к среднему доходу на душу населения, но ничего не добавляет к медиане.

Показатель отклонения: стандартное отклонение

Дисперсия представляет собой квадрат сигмы стандартного отклонения.

Мы делим на n или n-1?

$$\hat{\sigma} = \sqrt{\frac{\sum_{i}^{n}(x_i - \overline{x})^2}{n-1}}$$

СКО генеральной совокупности делится на n, СКО выборки на n-1 (почему – узнаем позже), но для больших n n ~ (n-1), так что это не имеет особого значения.

Интерпретация дисперсии (фондовый рынок)

Отношение «сигнал/шум» измерить сложно, поскольку многое из того, что вы видите, — это всего лишь дисперсия.

Рассмотрите возможность измерения относительного «навыка» различных инвесторов фондового рынка.

Ежегодные колебания эффективности фондов таковы, что результаты деятельности инвесторов случайны, а это означает, что реальная разница в навыках незначительна.

Интерпретация дисперсии (много моделей)

Обычно для каждой задачи мы разрабатываем несколько моделей, от очень простых до сложных.

Некоторая разница в производительности будет объяснена простой дисперсией: какие пары обучения/оценки были выбраны, насколько хорошо были оптимизированы параметры и т. д.

Небольшой выигрыш в производительности является аргументом в пользу более простых моделей.

Методы уменьшения дисперсии

Хотя идти на занятия пешком медленнее, чем ехать на автобусе, разница во времени прибытия меньше.

Повторение эксперимента несколько раз уменьшает дисперсию (перекрестная проверка в k-кратном размере).

То же самое относится и к правильной случайной и детерминированной выборке.

Устранение выбросов (если это оправдано) уменьшает дисперсию.

Распределение срока службы картриджей принтера

Распределения с одинаковым средним значением могут выглядеть очень по-разному.

Но вместе среднее и стандартное отклонение довольно хорошо характеризуют любое распределение.

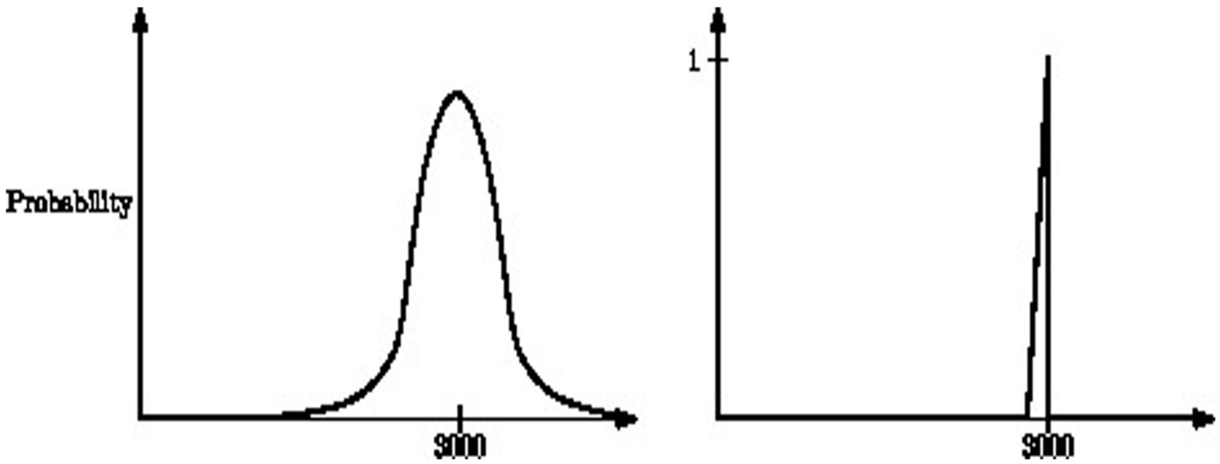

Приближенные вычисления

$$m_x^* = M^*[X] = \sum_{i=1}^{k} \tilde{x}_i p_i^*$$

$$D_x^* = D^*[X] = \sum_{i=1}^{k} (\tilde{x}_i - m_x^*)^2 p_i^*$$

$$\alpha_s^*[X] = \sum_{i=1}^{k} \tilde{x}_i^s p_i^*$$

$$\mu_s^*[X] = \sum_{i=1}^{k} (\tilde{x}_i - m_x^*)^s p_i^*$$

Выравнивание статистических рядов

- Во всяком статистическом распределении неизбежно присутствуют элементы случайности, связанные с тем. что число наблюдений ограничено, что произведены именно те, а не другие опыты, давшие именно те, а не другие результаты.
- Только при очень большом числе наблюдений эти элементы случайности сглаживаются, и случайное явление обнаруживает в полной мере присущую ему закономерность.
- На практике мы почти никогда не имеем дела с таким большим числом наблюдений и вынуждены считаться с тем, что любому статистическому распределению свойственны в большей или меньшей, мере черты случайности.
- Поэтому при обработке статистического материала часто приходится решать вопрос о том, как подобрать для данного статистического ряда теоретическую кривую распределения, выражающую лишь существенные черты статистического материала, но не случайности, связанные с недостаточным объемом экспериментальных данных. Такая задача называется задачей ***выравнивания*** (сглаживания) ***статистических рядов.***
- Задача выравнивания заключается в том, чтобы подобрать теоретическую плавную кривую распределения, с той или иной точки зрения наилучшим образом описывающую данное статистическое распределение.

Как выравнивать?

- Как правило, принципиальный вид теоретической кривой выбирается заранее из соображений, связанных с существом задачи, а в некоторых случаях просто с внешним видом статистического распределения. Аналитическое выражение выбранной кривой распределения зависит от некоторых параметров; задача выравнивания статистического ряда переходит в задачу рационального выбора тех значений параметров, при которых соответствие между статистическим и теоретическим распределениями оказывается наилучшим.

Например,

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x-m)^2}{2\sigma^2}} \qquad (1)$$

$$f(x) = \begin{cases} \dfrac{1}{\beta - \alpha}, \text{при } \alpha \le x \le \beta \\ 0, \text{при } x < \alpha \text{ или } x > \beta \end{cases} \qquad (2)$$

Что это за законы? Что будем подбирать?

Требуемые ограничения

$$f(x) \geq 0$$

$$\int_{-\infty}^{\infty} f(x)\, dx = 1$$

Метод моментов

- Согласно методу моментов, параметры ***a, b,*** . . . выбираются с таким расчетом, чтобы несколько важнейших числовых характеристик (моментов) теоретического распределения были равны соответствующим статистическим характеристикам.
- Например, если теоретическая кривая ***f(x)*** зависит только от двух параметров ***a*** и ***b,*** эти параметры выбираются так, чтобы математическое ожидание и дисперсия теоретического распределения совпадали с соответствующими статистическими характеристиками.
- Если кривая ***f(x)*** зависит от трех параметров, можно подобрать их так, чтобы совпали первые три момента, и т. д.
- При выравнивании статистических рядов может оказаться полезной специально разработанная система ***кривых Пирсона,*** каждая из которых зависит в общем случае от четырех параметров. При выравнивании эти параметры выбираются с тем расчетом, чтобы сохранить первые четыре момента статистического распределения (математическое ожидание, дисперсию, третий и четвертый моменты).

Пример

- С целью исследования закона распределения ошибки измерения дальности с помощью радиодальномера произведено 400 измерений дальности. Результаты опытов представлены в виде статистического ряда:

I_i (м)	20; 30	30; 40	40; 50	50; 60	60; 70	70; 80	80; 90	90; 100
m_i	21	72	66	38	51	56	64	32
p_i^*	0,052	0,180	0,165	0,095	0,128	0,140	0,160	0,080

Решение

https://colab.research.google.com/drive/1Ce0rPKw1jdU7mRzOkgNRiKIln68XDzR0

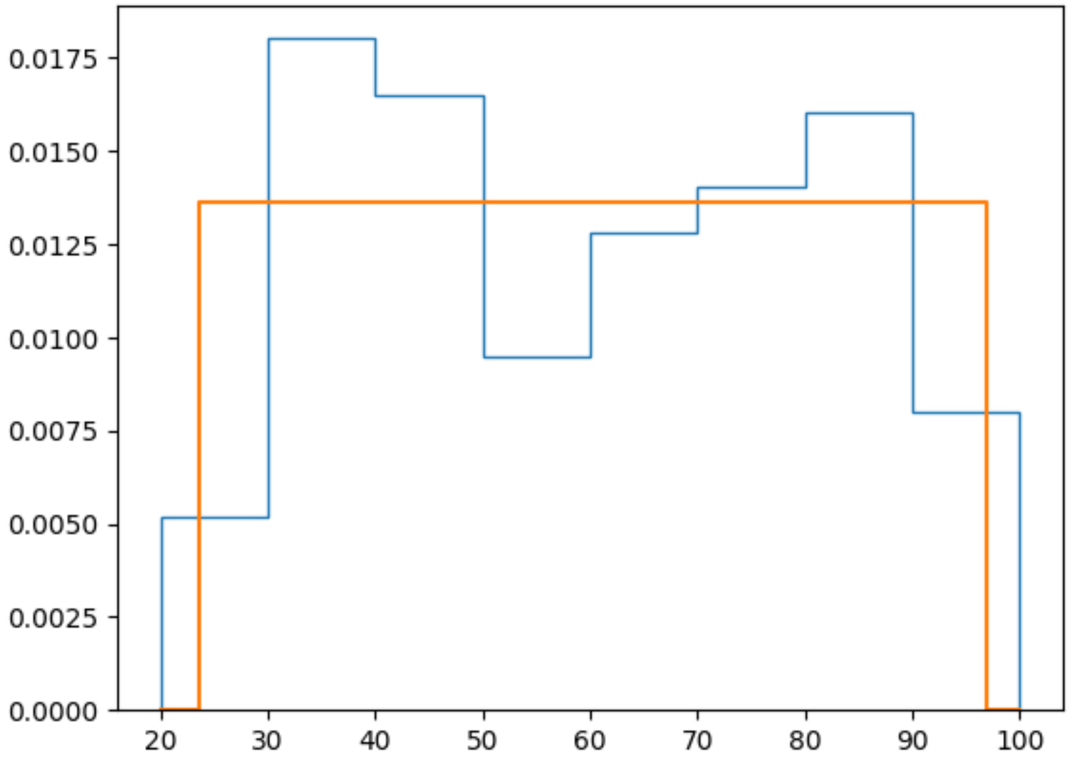

Критерии согласия

- Допустим, что данное статистическое распределение выравнено с помощью некоторой теоретической кривой

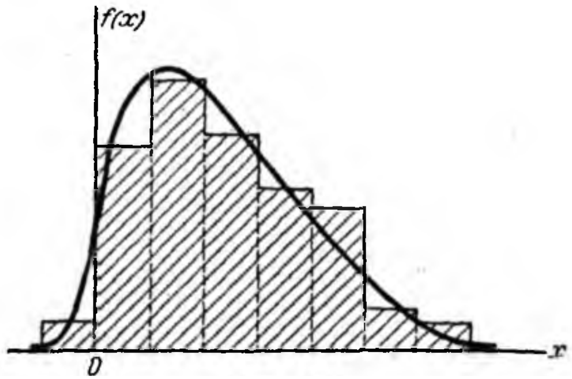

- Как бы хорошо, ни была подобрана теоретическая кривая, между нею и статистическим распределением неизбежны некоторые расхождения.
- Вопрос: объясняются ли эти расхождения только случайными обстоятельствами, связанными с ограниченным числом наблюдений, или они являются существенными и связаны с тем, что подобранная нами кривая плохо выравнивает данное статистическое распределение?
- Для ответа служат «критерии согласия».

Идея метода

- Гипотеза ***H***: случайная величина ***X*** подчиняется некоторому определенному закону распределения. Этот закон может быть задан в той или иной форме: например, в виде функции распределения ***F (x***) или в виде плотности распределения ***f (x) ,*** или же в виде совокупности вероятностей p_i **,** где p_i — вероятность того, что величина ***X*** попадет в пределы ***i***-го разряда.
- рассмотрим величину ***U ,*** характеризующую степень расхождения теоретического и статистического распределений.
- Величина ***U*** может быть выбрана различными способами; например, в качестве ***U*** можно взять сумму квадратов отклонений теоретических вероятностей p_i от соответствующих частот p_i ***** или же сумму тех же квадратов с некоторыми коэффициентами («весами»), или же максимальное отклонение статистической функции распределения ***F*(x)*** от теоретической ***F(x)*** и т. д. Допустим, что величина ***U*** выбрана тем или иным способом. Очевидно, это есть некоторая ***случайная величина.***

Идея метода (2)

- Закон распределения случайной величины ***U*** зависит от закона распределения случайной величины ***X*** ***,*** над которой производились опыты, и от числа опытов ***n.*** Если гипотеза ***H*** верна, то закон распределения величины ***U*** определяется законом распределения величины X (функцией F(x)) и числом ***n.***
- Допустим, что этот закон распределения нам известен. В результате данной серии опытов обнаружено, что выбранная нами мера расхождения ***U*** приняла некоторое значение ***u***.
- Можно ли объяснить это случайными причинами или же это расхождение слишком велико и указывает на наличие существенной разницы между теоретическим и статистическим распределениями и, следовательно, на непригодность гипотезы ***H***?

Идея метода (3)

- Предположим, что гипотеза ***H*** верна, и вычислим в этом предположении вероятность того, что за счет случайных причин, связанных с недостаточным объемом опытного материала, мера расхождения ***u*** окажется не меньше, чем наблюденное нами в опыте значение. Вычислим вероятность события:

$$U \geq u$$

- Если эта вероятность весьма мала, то гипотезу следует *отвергнуть* как мало правдоподобную
- Если же эта вероятность значительна, следует признать, что *экспериментальные данные не противоречат гипотезе **H**.*

Как следует выбирать U?

- При некоторых способах ее выбора закон распределения величины U обладает весьма простыми свойствами при достаточно большом n практически не зависит от функции $F(x)$.

Критерий Хи-квадрат Пирсона

- Произведено ***n*** независимых опытов, в каждом из которых случайная величина ***X*** приняла определенное значение. Результаты опытов сведены в *k* разрядов и оформлены в виде статистического ряда:

I_i	$x_1;\ x_2$	$x_2;\ x_3$	$\ldots$	$x_k;\ x_{k+1}$
p_i^*	p_1^*	p_2^*	$\ldots$	p_k^*

- Зная теоретический закон распределения, можно найти теоретические вероятности попадания случайной величины в каждый из разрядов:

$$p_1, p_2, \ldots p_k$$

- В качестве меры возьмем

$$U = \sum_{i=1}^{k} c_i (p_i^* - p_i)^2$$

Критерий Хи-квадрат Пирсона (2)

- Коэффициенты c_i («веса» разрядов) вводятся потому, что в общем случае отклонения, относящиеся к различным разрядам, нельзя считать равноправными по значимости.
- Одно и то же по абсолютной величине отклонение $p_i^* - p_i$ может быть мало значительным, если сама вероятность p_i велика, и очень заметным, если она мала. Поэтому естественно «веса» c_i взять обратно пропорциональными вероятностям разрядов p_i.
- ***Если положить***

$$c_i = \frac{n}{p_i}$$

то при больших n закон распределения величины U обладает весьма простыми свойствами:

он практически не зависит от функции распределения $F(x)$ и от числа опытов n, а зависит только от числа разрядов k,

Этот закон при увеличении n приближается к «распределению χ^2»

Мера расхождения

$$\chi^2 = n \sum_{i=1}^{k} \frac{(p_i^* - p_i)^2}{p_i} \qquad U = \chi^2 = \sum_{i=1}^{k} \frac{(m_i - p_i)^2}{np_i}$$

χ^2 с *r* степенями свободы – это распределение суммы квадратов *r* независимых случайных величин, каждая из которых подчинена нормальному закону с мат.ожиданием = *0* и дисперсией = 1.

Плотность распределения:

$$f_r(u) = \begin{cases} \frac{1}{2^{\frac{r}{2}}\Gamma(\frac{r}{2})} u^{\frac{r}{2}-1} e^{-\frac{u}{2}} \text{ при } u > 0 \\ 0 \text{ при } u \leq 0 \end{cases},$$

где $\Gamma(\alpha) = \int_0^\infty t^{\alpha-1} e^{-t} dt$ – гамма функция.

мат.ожидание $\mathrm{M}[U] = r$ и дисперсия $D[U] = 2r$.

Функция плотности распределения χ^2

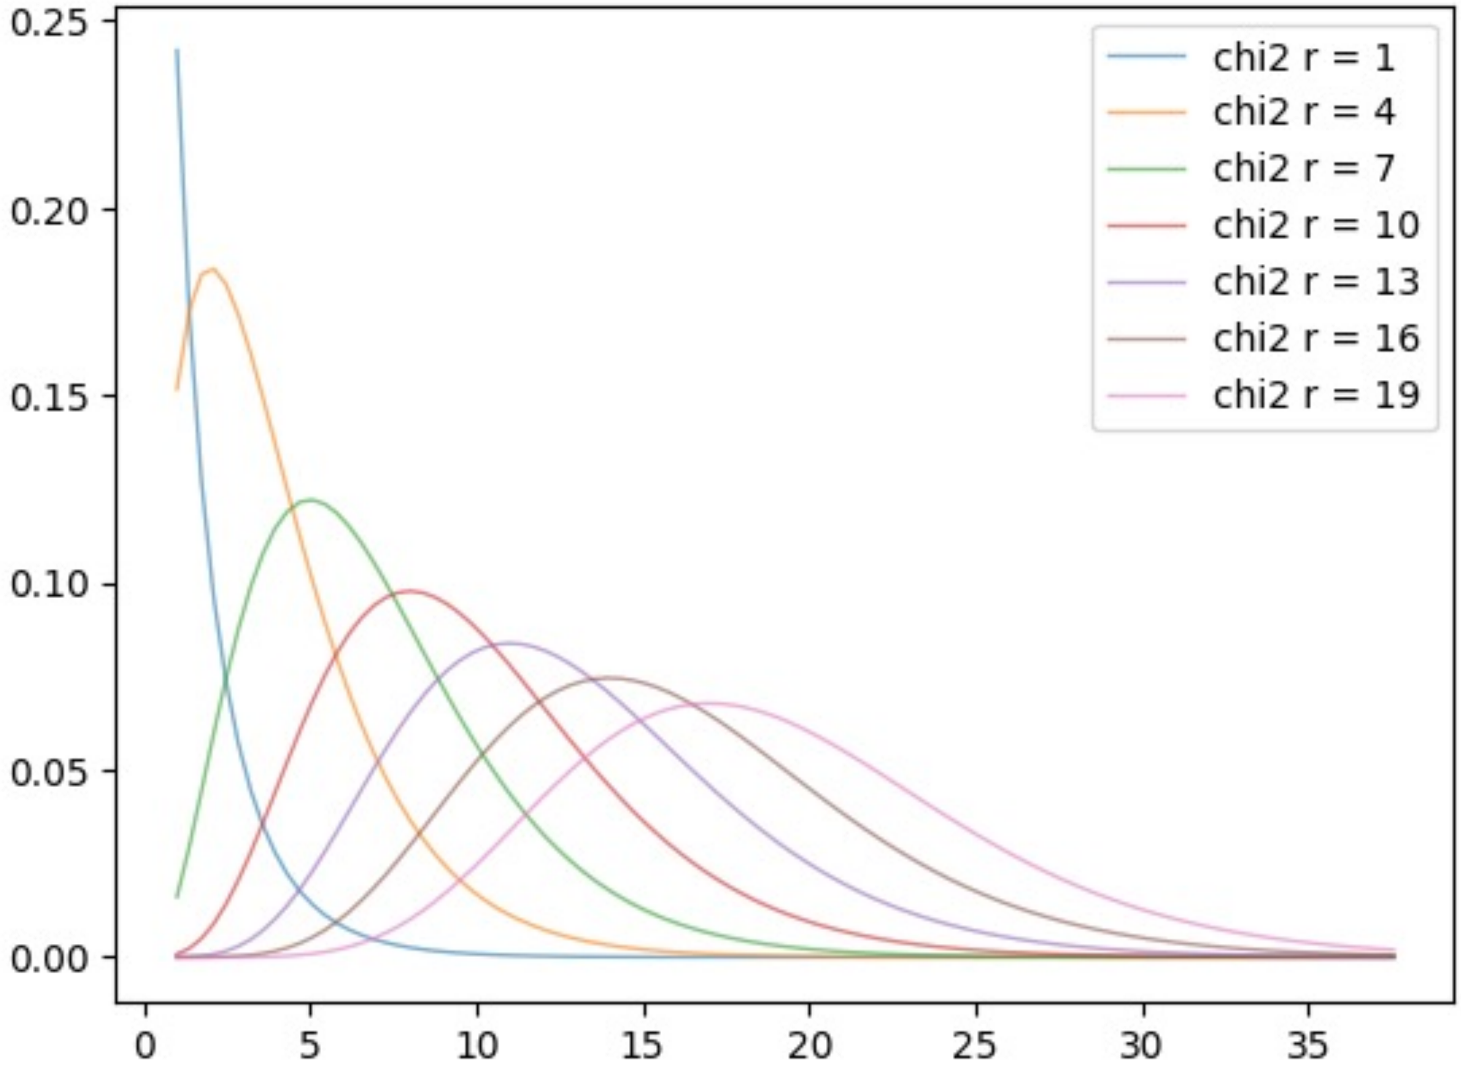

Как определить число степеней свободы

- Распределение χ^2 зависит от параметра ***r***, называемого числом «степеней свободы» распределения. Число «степеней свободы» *r* равно числу разрядов *k* минус число независимых условий («связей»), наложенных на частоты $\boldsymbol{p_i}$.
- ***Примеры условий:***

$$\sum_{i=1}^{k} p_i^* = 1$$

$$\sum_{i=1}^{k} \tilde{x}_i p_i^* = m_x$$

$$\sum_{i=1}^{k} (\tilde{x}_i - m_x^*)^2 p_i^* = D_x$$

Как посчитать критерий

https://colab.research.google.com/drive/1EuF6rmUqZtt8EQEThsVeiSbNZ8G7TKcx

Смысл p-value

- Распределение χ^2 дает возможность оценить степень согласованности теоретического и статистического распределений,
- Будем исходить из того, что величина ***X*** действительно распределена по закону ***F (x).***
- Тогда вероятность ***p (p-value)***, есть вероятность того, что за счет чисто случайных причин мера расхождения теоретического и статистического распределений будет не меньше, чем фактически наблюденное в данной серии опытов значение χ^2.
- Если эта вероятность***, p*** весьма мала (настолько мала, что событие с такой вероятностью можно считать практически невозможным), то результат опыта следует считать противоречащим гипотезе ***H*** о том, что закон распределения величины ***X*** есть ***F (x) .***
- Эту гипотезу следует отбросить как неправдоподобную. Напротив, если вероятность ***p*** сравнительно велика, можно признать расхождения между теоретическим и статистическим распределениями несущественными и отнести их за счет случайных причин. Гипотезу ***H*** о том, что величина ***X*** распределена по закону ***F*** (x), можно считать правдоподобной или, по крайней мере, не противоречащей опытным данным.

Смысл p-value

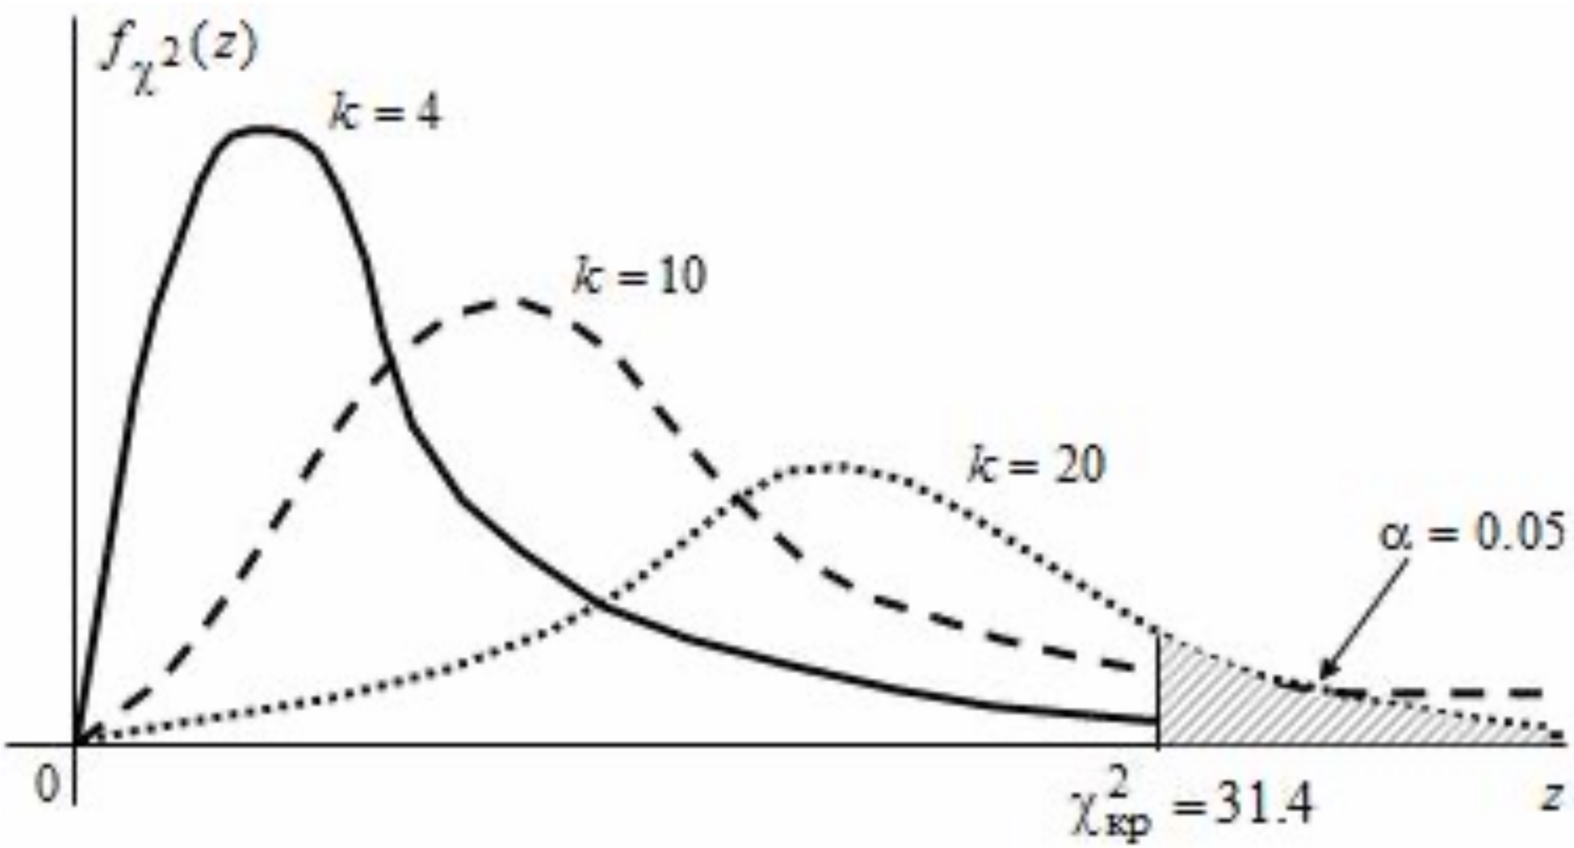

На сколько должно быть мало p-value?

- Вопрос неопределенный; он не может быть решен из математических соображений, так же как и вопрос о том, насколько мала должна быть вероятность события для того, чтобы считать его практически невозможным.
- На практике, если ***p*** оказывается меньшим чем 0,1, рекомендуется проверить эксперимент, если возможно — повторить его и в случае, если заметные расхождения снова появятся, пытаться искать более подходящий для описания статистических данных закон распределения.
- С помощью критерия χ^2 (или любого другого критерия согласия) можно только в некоторых случаях ***опровергнуть*** выбранную гипотезу ***H*** и отбросить ее как явно несогласную с опытными данными.
- Если же вероятность ***p*** велика, то этот факт сам по себе ни в коем случае не может считаться доказательством справедливости гипотезы ***H,*** а указывает только на то, что гипотеза не противоречит опытным данным.

Критерий Колмогорова

$$D = \max|F^*(x) - F(x)|$$

- Какова бы ни была функция распределения F(***x***) непрерывной случайной величины ***X***, при неограниченном возрастании числа независимых наблюдений ***n*** вероятность неравенства

$$D\sqrt{n} \geq \lambda$$

- стремится к пределу

$$P(\lambda) = 1 - \sum_{k=-\infty}^{\infty} (-1)^k e^{-2k^2\lambda^2}$$

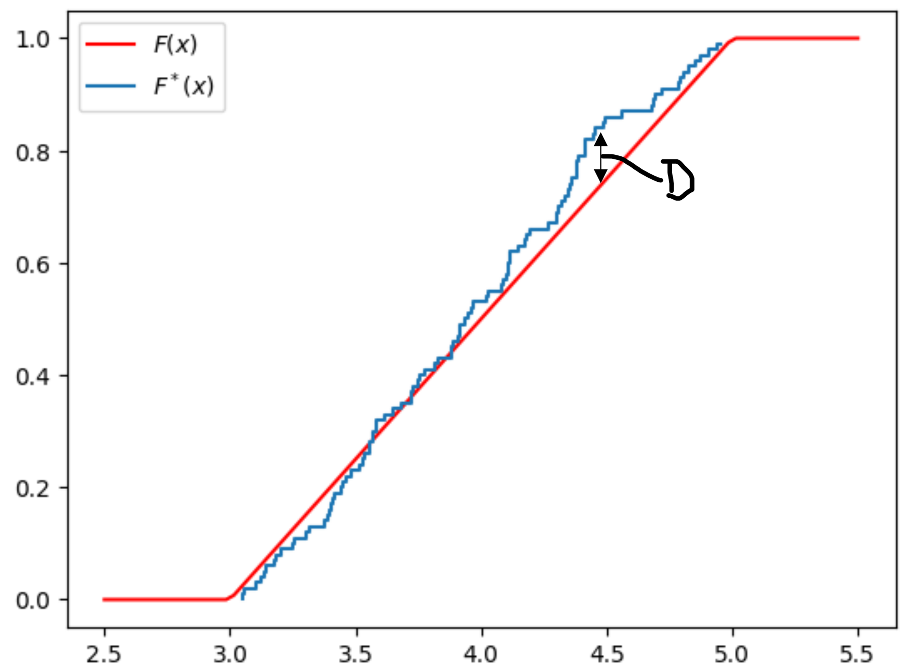

Как посчитать критерий Колмогорова

https://colab.research.google.com/drive/1g9aS5RpoBYB-xcwreZ0TCns0RBBL-mdv

Критерий Колмогорова. Когда применим?

- можно применять только в случае, когда гипотетическое распределение ***F(x)*** полностью известно заранее из каких-либо теоретических соображений, т. е. когда известен не только вид функции распределения ***F (x),*** но и все входящие в нее параметры.
- Такой случай сравнительно редко встречается на практике. Обычно из теоретических соображений известен только общий вид функции ***F(x)****, а* входящие в нее числовые параметры определяются по данному статистическому материалу.
- При применении критерия χ^2 это обстоятельство учитывается соответствующим уменьшением числа степеней свободы распределения χ^2**.** Критерий А. Н. Колмогорова такого согласования не предусматривает. Если все же применять этот критерий в тех случаях, когда параметры теоретического распределения выбираются по статистическим данным, критерий дает заведомо завышенные значения вероятности P(X); поэтому мы в ряде случаев рискуем принять как правдоподобную гипотезу, в действительности плохо согласующуюся с опытными данными.

Оценка параметров

- Для поиска закона распределения нужно много наблюдений
- А что делать если их мало?
- На основе ограниченного числа наблюдений приблизительно найти параметры законов – мат. ожидание, дисперсия …
- Любая оценка на основе опытов – случайная величина
- Будем заниматься поиском «оценок параметров»
- Желательно найти оценку с минимальной ошибкой

Общая задача оценки параметров

Дано:

Наблюдения сл.величины X: $X_1, X_2, \dots, X_n$. Закон распределения наблюдений одинаков

Пусть $\tilde{a} = \tilde{a}(X_1, X_2, \dots, X_n)$ – оценка

$\tilde{a}$ - это функция

$\tilde{a}$ - это случайная величина

Закон распределения $\tilde{a}$ зависит от:

1) закона распределения X

2) числа наблюдений n

Нужно найти $\tilde{a}$ удовлетворяющую требованиям на следующем слайте

Требования к оценке $\tilde{a}$

- Состоятельность: при увеличении n оценка $\tilde{a}$ должна сходиться по вероятности к параметру a.
- Несмещенность: $\mathrm{M}[\tilde{a}] = a$
- Эффективность: $\mathrm{D}[\tilde{a}] \to \min$

Оценка $\tilde{a}$ должна быть получена за приемлемое время, поэтому требования могут немного нарушаться.

Оценка мат.ожидания

$$\tilde{m} = \frac{\sum_{i=1}^{n} X_i}{n}$$

Состоятельность: следует из закона больших чисел

Несмещенность: $M[\tilde{m}] = \frac{\sum_{i=1}^{n} m}{n} = m$

Эффективность?

$$\mathrm{D}[\tilde{m}] = \frac{\sum_{i=1}^{n} D}{n^2} = \frac{1}{n} D$$

Для нормального закона – эффективна, для других может быть не так.

Оценка дисперсии

Предположим: $D^* = \frac{\sum_{i=1}^{n}(X_i - \widetilde{m})^2}{n}$

Состоятельность:

$$D^* = \frac{\sum_{i=1}^{n} X_i{}^2}{n} - \widetilde{m}^2$$

$$\alpha_2[X] - m^2 = D \ \blacksquare$$

Несмещенность?

$$D^* = \frac{\sum_{i=1}^{n} X_i{}^2}{n} - \left(\frac{\sum_{i=1}^{n} X_i}{n}\right)^2 = \frac{\sum_{i=1}^{n} X_i{}^2}{n} - \frac{\sum_{i=1}^{n} X_i{}^2}{n^2} - 2\frac{\sum_{i<j} X_i X_j}{n^2} = \frac{(n-1)\sum_{i=1}^{n} X_i{}^2}{n^2}$$
$$- 2\frac{\sum_{i<j} X_i X_j}{n^2}$$

$$M[\widetilde{D}] = \frac{(n-1)}{n^2}\sum_{i=1}^{n} M[X_i{}^2] - \frac{2}{n^2}\sum_{i<j} M[X_i X_j]$$

Несмещенность дисперсии

$$M[D^*] = \frac{(n-1)}{n^2} \sum_{i=1}^{n} M[X_i{}^2] - \frac{2}{n^2} \sum_{i<j} M[X_i X_j]$$

Пусть начало координат будет в точке m. Тогда

$$M[X_i{}^2] = M[\dot{X}_i{}^2] = D; \quad \sum_{i=1}^{n} M[X_i{}^2] = nD$$

$M\left[X_i X_j\right] = M\left[\dot{X}_i \dot{X}_j\right] = K_{ij} = 0$, так как опыты независимы

$$M[D^*] = \frac{(n-1)}{n} D$$

Несмещенная оценка дисперсии

$$\widetilde{D} = \frac{n}{n-1} D^* = \frac{\sum_{i=1}^{n}(X_i - \widetilde{m})^2}{n-1}$$

Если $n \to \infty$, то $\frac{n}{n-1} \to 1$, поэтому если D^* состоятельна, то $\widetilde{D}$ состоятельна.

Иногда удобней вычислить:

$$\widetilde{D} = \left[\frac{\sum_{i=1}^{n} {X_i}^2}{n} - \widetilde{m}^2\right]\frac{n}{n-1}$$

Доверительный интервал

К каким ошибкам может привести замена a на $\tilde{a}$?

Найти ε для β=0.9, 0.95, 0.99, чтобы

$$P(|a - \tilde{a}| < \varepsilon) = \beta$$

$$P(\tilde{a} - \varepsilon < a < \tilde{a} + \varepsilon) = \beta$$

$$I_\beta = (\tilde{a} - \varepsilon;\ \tilde{a} + \varepsilon) - \text{доверительный интервал}$$

Что тут случайно? a или I_β?

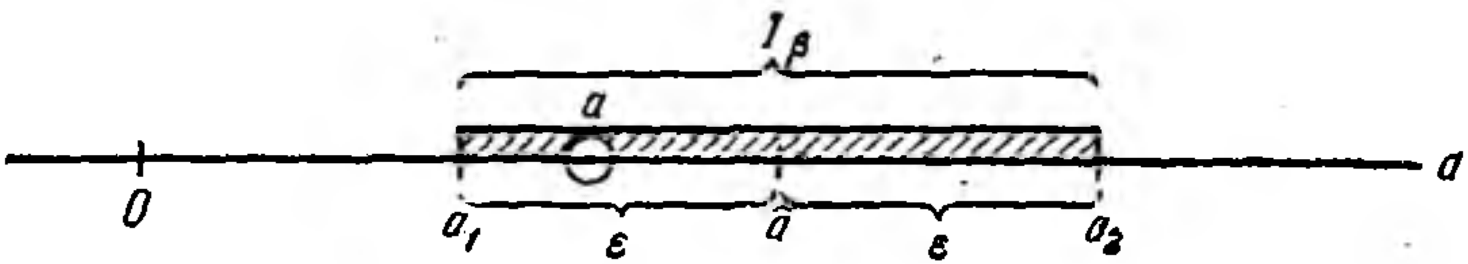

β- доверительная вероятность

Нахождение доверительного интервала для мат.ожидания

$$\tilde{m} = \frac{\sum_{i=1}^{n} X_i}{n}; \quad \tilde{D} = \frac{\sum_{i=1}^{n}(X_i - \tilde{m})^2}{n-1}$$

При большом n (на практике даже для n 10-20) закон распределения $\tilde{m}$ приближенно можно считать нормальным. Параметры m и $\frac{D}{n}$.

$$P\left(|a - \tilde{a}| < \varepsilon_\beta\right) = \beta$$

$$P\left(|a - \tilde{a}| < \varepsilon_\beta\right) = 2\Phi^*\left(\frac{\varepsilon_\beta}{\sigma_{\tilde{m}}}\right) - 1,$$

$$\sigma_{\tilde{m}} = \sqrt{D/n}$$

$$2\Phi^*\left(\frac{\varepsilon_\beta}{\sigma_{\tilde{m}}}\right) - 1 = \beta, \qquad \varepsilon_\beta = \sigma_{\tilde{m}}\Phi^{-1}\left(\frac{1+\beta}{2}\right)$$

Приближенно $\sigma_{\tilde{m}} = \sqrt{\tilde{D}/n}$

$$t_\beta = \Phi^{-1}\left(\frac{1+\beta}{2}\right)$$

$$I_\beta = \left(\tilde{m} - \sigma_{\tilde{m}} t_\beta; \tilde{m} + \sigma_{\tilde{m}} t_\beta\right)$$

Пример нахождения доверительного интервала для мат.ожидания

https://colab.research.google.com/drive/16VGMdfp8xvsBNBhMttWlzsJHuLKXPc6D

Доверительный интервал для дисперсии

$$\widetilde{D} = \frac{\sum_{i=1}^{n}(X_i - \widetilde{m})^2}{n-1}; \ \widetilde{m} = \frac{\sum_{i=1}^{n} X_i}{n}$$

$\frac{(X_i - \widetilde{m})^2}{n-1}$ - величины не являются независимыми, они зависят от $\widetilde{m}$ куда входят все. Но при n 2—30 гео можно считать нормальным.

$$M\left[\widetilde{D}\right] = D$$

$$D\left[\widetilde{D}\right] = \frac{1}{n}\mu_4 - \frac{n-3}{n(n-1)}D^2$$

$\mu_4^* = \frac{\sum_{i=1}^{n}(X_i - \widetilde{m})^4}{n}$ даст невысокую точность

Доверительный интервал для дисперсии (2)

Для нормального закона: $\mu_4 = 3D^2$

$$D[\widetilde{D}] = \frac{3}{n}D^2 - \frac{n-3}{n(n-1)}D^2$$

$$D[\widetilde{D}] = \frac{2}{n-1}D^2. \ D[\widetilde{D}] = \frac{2}{n-1}\widetilde{D}^2. \sigma_{\widetilde{D}} = \sqrt{\frac{2}{n-1}}\,\widetilde{D}$$

Для равномерного закона:

$$\mu_4 = \frac{(\beta-\alpha)^4}{80}; \quad D = \frac{(\beta-\alpha)^2}{12}$$

$$\mu_4 = 1.8D^2$$

$$D[\widetilde{D}] = \frac{0.8n+1.2}{n(n-1)}D^2. \sigma_{\widetilde{D}} = \sqrt{\frac{0.8n+1.2}{n(n-1)}}\,\widetilde{D}$$

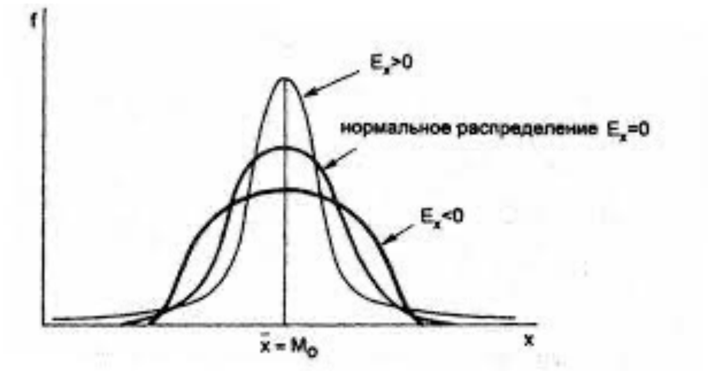

Когда закон не известен и нет оснований считать что он сильно отличается от нормального (не обладает заметным эксцессом), то рекомендуется считать $\sigma_{\widetilde{D}}$ по формуле для нормального закона.

$$I_\beta = (\widetilde{D} - \sigma_{\widetilde{D}} t_\beta; \widetilde{m} + \sigma_{\widetilde{D}} t_\beta)$$

Пример нахождения доверительного интервала для дисперсии

https://colab.research.google.com/drive/16VGMdfp8xvsBNBhMttWlzsJHuLKXPc6D

Точные методы построения доверительных интервалов

- Для точного нахождения доверительных интервалов нужно знать закон распределения X
- Параметры этого закона иногда можно и не знать. Задача решается путем перехода к другой случайной величине.
- Например, для нормального закона.

Доверительные интервалы дла нормального закона

$$T = \sqrt{n}\frac{\widetilde{m} - m}{\sqrt{\widetilde{D}}}$$

Подчиняется закону распределения Стьюдента с n-1 степенью свободы:

$$S_{n-1}(t) = \frac{\Gamma\left(\frac{n}{2}\right)}{\sqrt{(n-1)\pi}\,\Gamma\left(\frac{n-1}{2}\right)}\left(1 + \frac{t^2}{n-1}\right)^{-\frac{n}{2}}$$

где $\Gamma(x)$ — известная гамма-функция:

$$\Gamma(x) = \int_0^\infty u^{x-1} e^{-u}\, du.$$

Доверительные интервалы для нормального закона

$$V = \frac{(n-1)\widetilde{D}}{D}$$

имеет распределение хи-квадрат с n-1 степенью свободы.

$$k_{n-1}(v) = \begin{cases} \dfrac{1}{2^{\frac{n-1}{2}}\Gamma(\dfrac{n-1}{2})} u^{\frac{n-1}{2}-1} e^{-\frac{v}{2}} \text{ при } v > 0 \\ 0 \text{ при } v \le 0 \end{cases},$$

Переход к величине T

$$P(|m-\tilde{m}|<\varepsilon_\beta)=\beta \qquad T=\sqrt{n}\frac{\tilde{m}-m}{\sqrt{\tilde{D}}}$$

$$P\left(\sqrt{n}\frac{|\tilde{m}-m|}{\sqrt{\tilde{D}}}<\frac{\varepsilon_\beta}{\sqrt{\frac{\tilde{D}}{n}}}\right)=\beta \quad P\left(|T|<\frac{\varepsilon_\beta}{\sqrt{\frac{\tilde{D}}{n}}}\right)=\beta$$

$$P(|T|<t_\beta)=\beta \quad P(|T|<t_\beta)=\int_{-t_\beta}^{t_\beta}S_{n-1}(t)dt$$

Так $S_{n-1}(t)$ четная функция: $2\int_0^{t_\beta}S_{n-1}(t)dt=\beta$ по таблице можно найти t_β по заданному β.

$$\varepsilon_\beta=t_\beta\sqrt{\frac{\tilde{D}}{n}}. \qquad I_\beta=\left(\tilde{m}-t_\beta\sqrt{\frac{\tilde{D}}{n}};\tilde{m}+t_\beta\sqrt{\frac{\tilde{D}}{n}}\right)$$

Пример расчетов интервала мат.ожидания Т-критерием

https://colab.research.google.com/drive/1H2oZnJRXir3GrjzHHZtqcmNkr89OfL9y

Точный интервал для дисперсии

$$V = \frac{(n-1)\tilde{D}}{D} \qquad \tilde{D} = V\frac{D}{(n-1)}$$

Закон не симметричен

Условимся выбирать интервал так чтобы слева и справа была одинаковая площадь:

$$p = \frac{\alpha}{2} = \frac{1-\beta}{2} \qquad P(V > \chi^2) = p$$

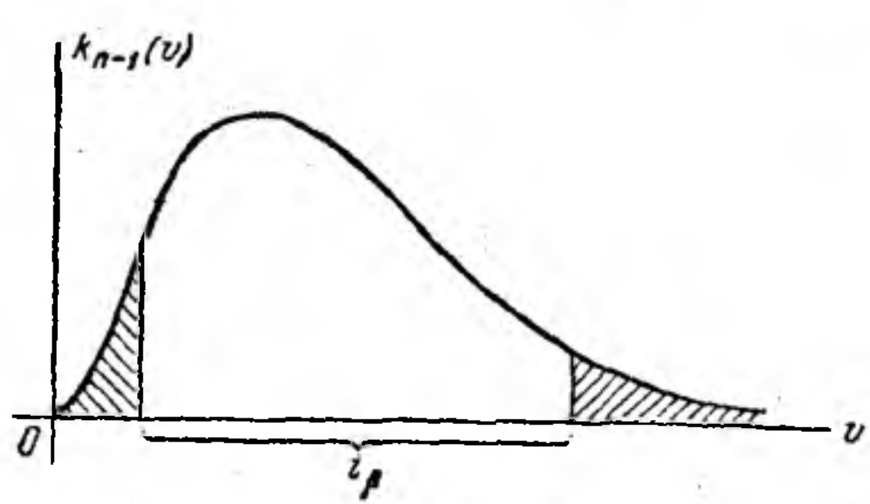

Точный интервал для дисперсии (2)

$$P(D_1 < D < D_2) = \beta$$

$$I_\beta = \left(\frac{\widetilde{D}(n-1)}{\chi_1^2}; \frac{\widetilde{D}(n-1)}{\chi_2^2}\right)$$

$$\frac{\widetilde{D}(n-1)}{\chi_1^2} < D; \frac{\widetilde{D}(n-1)}{\chi_2^2} > D$$

Равносильно

$$\mathrm{V} < \chi_1^2; V > \chi_2^2$$

Пример расчетов интервала дисперсии V-критерием

https://colab.research.google.com/drive/1H2oZnJRXir3GrjzHHZtqcmNkr89OfL9y